

论文阅读：LLM4PG - 让大模型自己学会预测信号覆盖图

一.概括:

LLM4PG = 让大模型看“无人机拍的RGB图和深度图” → 直接生成“信号覆盖图 (Pathloss Map)

first time. The proposed general LLM4PG is demonstrated in 3D high-mobility U2G scenarios, utilizing RGB images and depth maps to achieve cross-modal pathloss map generation. Built upon the architecture and methodology of the Synth-SoM dataset [25], a new synthetic intelligent multi-modal sensing-communication dataset for SoM in U2G scenarios

通俗理解:

RadioSim Agent: 每次都要现场做射线追踪, 算得慢但精确

LLM4PG: 先让AI看大量 (RGB图+深度图, 信号覆盖图) 的数据, 学会“看图猜信号”, 以后直接秒出结果

几个概念解释:

- RGB图 = 普通彩色照片, 告诉你“这个位置是什么颜色”
- 深度图 = 一张灰度图, 告诉你“这个位置离我有多远”
- 信号覆盖图 = 一张地图, 告诉你“在这个位置的信号有多强”

二、背景：为什么要做这件事？

传统信号预测方法的痛点:

方法	优点	缺点
经验公式（如3GPP标准）	计算快	不准确，只能大概估计
射线追踪（Ray-Tracing）	非常准确	算得太慢了，大规模用不起
传统深度学习（如ResNet、GAN）	比公式准，比射线追踪快	模型太小，"脑子不够大"，遇到新场景、新高度、新频段就懵了

rithm validation. However, in the emerging sixth-generation (6G) communications, communication systems are evolving toward AI-native paradigms, where AI is deeply integrated into system design to significantly enhance performance [8], [9]. Therefore, the scale and quality of data determine the

核心矛盾：

- 6G需要海量、高质量的信号数据来训练AI
- 射线追踪太慢，做不了海量数据
- 传统AI不够准，质量不够高

论文想法：

能不能用一个"更聪明、见识更广"的模型——大语言模型（LLM）——来做这件事？

三、核心创新点：机器的联觉（SoM）

or low accuracy. To fill this gap, inspired by synesthesia of human, a novel concept, i.e., Synesthesia of Machines (SoM), which refers to intelligent multi-modal sensing-communication integration, was proposed in [10]. Within the

讲解：

联觉本来是心理学概念，指有些人"听到颜色"或"看到声音"——比如听到音乐时眼前会浮现颜色。

机器的联觉就是说：让机器像人一样，能把不同"感官"的信息联系起来。在这篇论文里：

- **视觉感官**：无人机拍的RGB照片（看建筑物长啥样）+ 深度图（看离地面多远）
- **电磁感官**：信号频率是多少（1.6GHz还是28GHz）
- **输出**：信号覆盖热力图（路径损耗图）

四、数据集：SynthSoM-U2G

要做这个研究，首先得有数据。论文构建了一个叫 SynthSoM-U2G 的合成数据集。

Following the framework and methodology established in the SynthSoM dataset [25], a new synthetic intelligent multi-modal sensing-communication dataset for SoM in U2G scenarios, named SynthSoM-U2G, is constructed to explore the mapping mechanism between sensing image and pathloss map. The dataset contains multi-modal sensing images, i.e.,

收集方式：

软件	用途	收集什么
AirSim	无人机仿真	RGB照片 + 深度图（视觉信息）
Wireless InSite	无线通信仿真	路径损耗值（通信信息）

场景设置：

- **两个城市场景**：十字路口（建筑密集）、宽马路（建筑更高更密）
- **两个频段**：1.6GHz（低频，绕射能力强）和 28GHz（毫米波，高频，容易被挡住）
- **三个飞行高度**：50m、70m（十字路口）、200m（宽马路）

数据规模：

- 9,490张路径损耗图
- 5,660张RGB图 + 5,660张深度图

关键难点：

两个软件要严格"对齐"——无人机在同一时刻、同一位置，同时拍照片和算信号损耗。 五、模型架构：LLM4PG 的三板斧

五.模型架构：LLM4PG 的三板斧

通俗讲解：

LLM4PG 就像一条"生产线"，分三个车间：

[输入] → [Embedding模块] → [LLM backbone] → [Decoder模块] → [输出路径损耗图]

车间1：Embedding模块（“翻译官”）

任务：把五花八门的数据，翻译成LLM能懂的“语言”（token序列）。

two components, i.e., feature extraction and feature fusion. For the feature extraction, RGB images and depth maps in physical environment and carrier frequency information in electromagnetic space are considered and processed. Specif-

具体做法：

1. **RGB图和深度图**：切成小方块（patch），像ViT（视觉Transformer）那样，每个方块变成一个token，加上位置信息
2. **频率信息**：用一个简单神经网络（MLP）把频率数字变成特征向量
3. **融合**：把三种特征拼在一起——RGB特征 + 深度图特征 + 频率特征 = "物理-电磁联合特征"

概念解释：

术语	一句话解释
ViT	把图片切成小块，让AI像读文章一样读图
MLP	最简单神经网络，输入一个数，输出一长串数
频率→特征向量	把“28”这样的数字，通过MLP“扩写”成一长串有意义的信息

这三个操作的目标是统一的：把RGB图、深度图、频率这三种“原始数据”，全部转成LLM（GPT-2）能读懂的“语言”（token序列/特征向量）。

这就是Embedding模块（“翻译官”）在做的事。

车间2：LLM Backbone（“大脑”）

任务：用预训练的大语言模型来理解“物理环境 → 电磁空间”的映射关系。

environment and electromagnetic space. To balance the trade-off between complexity and performance, the first $n_L = 6$ layers of the pre-trained GPT-2 are utilized for fine-tuning. Note that in the pre-trained GPT-2 model, the self-attention and feed-forward layers are frozen, with the remaining parameters open for training. Since these fixed layers account

选的是GPT-2：

- 为什么选GPT-2？擅长“序列建模”，大小适中，微调成本可控
- 它有几层Transformer，天然适合处理“图片切块”这种序列

微调策略（关键！）：

- 冻结：自注意力层和前馈层（这些是大头，预训练知识在这里）
- 激活训练：其他层（如LayerNorm等）

车间3：Decoder模块（“画图师”）

任务：把LLM输出的“电磁特征”，还原成一张路径损耗热力图。

The decoder module decodes the electromagnetic space features into the pathloss map. First, to reconstruct high-resolution pathloss images from compressed electromagnetic features, the transposed convolution layer is utilized due to its effectiveness for upsampling latent representations. Sec-

结构：

- 转置卷积（上采样）：把小图放大成原图大小
- 批归一化：稳定训练
- LeakyReLU：激活函数，防止“神经元死亡”

重复 3 次（ $n_D = 3$ ），最后输出一张二维图像。

概念解释：

卷积 = 一个“小窗口”在图片上滑动，每次提取一小块区域的特征。

LLM4PG的Decoder模块里用了转置卷积（也叫反卷积）：

卷积类型	作用	方向
普通卷积	把大图变小（下采样）	→
转置卷积	把小图变大（上采样）	←

六、实验结果

实验1：全样本性能（LLM4PG在全部数据上训练，效果有多好？）

评价指标：NMSE（归一化均方误差），越小越好

可视化结果

- LLM4PG生成的信号覆盖图，建筑边界更清晰
- GAN生成的图模糊，信号强度数值偏差大

一句话总结：LLM4PG在所有测试条件下都比传统AI准得多，RGB+深度图一起用效果最好。